Домашнее задание 6 (unsupervised). Типология клиентской базы

Продуктовая команда говорит: «У нас 20 тысяч клиентов и один тариф на всех. Мы перестраиваем линейку и не знаем, на кого её делить. Нужна типология: сколько типов клиентов, чем они отличаются, как их назвать и что каждому предлагать. Сколько типов и какие, решаете вы. Такого справочника у нас нет и никогда не было».

Обратите внимание: здесь нет и не может быть правильного ответа. Тип клиента это не факт из базы, а конструкция, которую вы создаёте и защищаете. Ни в одной таблице нет колонки с ответом, и никакая метрика не скажет вам, что вы угадали. Доказательство качества придумываете вы сами.

Данные

Postgres, база academy_db, схема public. Таблицы с префиксом seg_, данные за 2024 и 2025 годы.

`postgresql://ВАШ_ЛОГИН:ВАШ_ПАРОЛЬ@thomas.proxy.rlwy.net:51432/academy_db`

Есть операции по картам с каналом и категорией, ежемесячные остатки, подключённые продукты, доходность каждого клиента по месяцам и текущий единый тариф. Как и в прошлых выгрузках, здесь есть лишнее: старые витрины, чужие расчёты, служебные копии. Что использовать, решаете сами.

Что сделать

1. **Выбрать окно наблюдения.** Данные за два года, но клиенты пришли в разное время, а поведение человека со временем меняется. Среднее за 24 месяца может описывать человека, которого никогда не существовало. Решите, за какой период считать признаки, и объясните почему.
2. **Выбрать оси.** По чему вообще делить базу: по тратам, каналам, деньгам для банка, стадии жизни клиента? Разные оси дадут разные типологии, и все они будут по-своему верны. Ваш выбор нужно обосновать.
3. **Построить типологию.** Метод любой. Важно не какой алгоритм, а сколько получилось классов и почему именно столько. Ответ «столько показал локоть» не принимается: посмотрите на данные внимательно и поймёте почему.
4. **Сравнить с простым разбиением.** Разбейте базу на четыре части просто по обороту, по квартилям. Докажите, что ваша типология содержательно лучше этого разбиения. Если не лучше, так и скажите, это честный результат.
5. **Доказать устойчивость числом.** Не словами «выглядит стабильно», а мерой совпадения разбиений (например ARI) при: другом random_state, половине выборки, данных без последнего месяца, слегка изменённом наборе признаков. Приведите таблицу.
6. **Показать, что типологию можно применять.** Завтра придёт новый клиент. Как вы определите его тип? Опишите правило и проверьте его на клиентах, которых не было в обучении.
7. **Назвать классы.** Человеческим языком, так чтобы продуктовый менеджер описал каждый одной фразой. «Кластер 3» не годится.

8. **Показать деньги.** Для каждого типа: сколько людей, сколько банк на них зарабатывает сейчас, что предлагаем и что рассчитываем получить.

Что сдать

Презентация с карточкой на каждый тип и разделом про устойчивость, ноутбук с кодом, SQL сборки признаков. Ответы вносите в форму задания на платформе, файлы прикрепляете там же.

КРИТЕРИЙ	БАЛЛЫ
Окно наблюдения выбрано осознанно, разная длина истории учтена	15
Выбор осей обоснован, не взяты все колонки подряд	10
Число классов защищено, рассмотрены альтернативы	15
Сравнение с разбиением по квартилям оборота проведено	15
Устойчивость измерена числом, приведена таблица	20
Правило отнесения нового клиента описано и проверено	10
Классы названы, размер и деньги посчитаны, предложение конкретное	15

Частые ошибки

- Посчитать признаки за весь период сразу. Клиенты пришли в разное время, и у кого-то истории два года, а у кого-то два месяца. Типология получится по стажу, а не по поведению.
- Не заметить, что часть клиентов вела себя одним образом, а потом стала вести себя иначе. Среднее по такому человеку не описывает ни то, ни другое поведение.
- Взять готовый сегмент из старой витрины и выдать за свой результат. Сначала проверьте, отличаются ли эти сегменты хоть чем-нибудь.
- Забыть про несколько клиентов с огромными оборотами. Они утащат центры кластеров на себя, и половина базы окажется в одной группе.
- Не масштабировать признаки, после чего типология определяется одной колонкой с самыми большими числами.
- Получить сегмент из двухсот человек и предложить под него отдельный тариф.
- Сделать красивые кластеры, которые не меняют ни одного решения бизнеса.